


KI-Agent "Jarvis" - Masterplan Version 3

Lokaler Sprachassistent, Morning Market Briefing, Recherche- und Business-Agent -
kostenkontrolliert, wiederaufbaubar und vorbereitet fuer Hermes/Multi-Agent.



Stand: 30. April 2026

Leitentscheidung: Lokal-first. Cloud/APIs nur dort, wo sie einen messbaren Mehrwert liefern. Zielkosten MVP: 0-30 USD/Monat, bevorzugt 0 USD/Monat plus Strom/Hardware.

Aktueller Zustand: Jarvis ist ein funktionierender lokaler AI-Agent-Prototyp mit Market-Briefing-Pipeline, Voice-Eingang, LLM-basierter Intent-Erkennung, TTS-Ausgabe und GitHub-Recovery-Strategie.

1. Zielbild und Mindset

- Jarvis als lokaler Arbeitsplatz-Agent: Sprache rein, strukturierte Antwort raus, optional gesprochen.
- Morning Market Briefing: Gold, Forex, Dollar, Renditen, Makro, Risiken und Bias als Markdown in Obsidian.
- Voice-Steuerung als Frontend: aktuell Wake Word "Computer"; "Jarvis" bleibt spaeter optional.
- Business Development: Marktideen, Lead-Recherche, Wettbewerbsbeobachtung, Angebots- und Mail-Entwuerfe.
- Recovery by design: Nach Datenverlust muss das System aus GitHub, diesem Dokument und Secrets aus Passwortmanager wiederherstellbar sein.
- Keine Blackbox-Autonomie: Analyse, Vorbereitung und Vorschlaege ja; E-Mail-Versand, Trading, Loeschung, Upload nur nach Freigabe.


V3-Leitsatz: Nicht jedes falsch erkannte Wort wird hart verdrahtet. Whisper liefert Text, OpenJarvis/Ollama interpretiert die Bedeutung und waehlt den passenden Intent.

Aktuelles Zielbild

Ebene	Ziel	Status
Voice	Natuerliche Sprache als Bedienoberflaeche	MVP laeuft, UX noch zu verbessern
Market Agent	Bericht erstellen und zusammenfassen	laeuft
Recovery	PC2 aus GitHub reproduzierbar aufsetzen	Grundlage steht
Hermes	Planner/Multi-Step-Agent hinter Router	geplant, nicht ersetzt

2. Architekturuebersicht

Die Architektur trennt Windows-Voice, WSL-Backend, lokale Modelle, Tools, Daten und Backup. Dadurch kann spaeter Hermes als Planner eingefuegt werden, ohne Voice oder Market-Pipeline neu zu bauen.



Systemgrenzen

Bereich	Laufzeitort	Aufgabe
Windows	C:\jarvis-voice	Mikrofon, faster-whisper, Wake Word, Windows SAPI TTS, Agent Router
WSL/Ubuntu	/home/home/jarvis	OpenJarvis, Ollama, Market Scripts, Obsidian-Ausgabe, Installer
GitHub	github.com/weichwiebutter/jarvis	Code, Setup-Dateien, Dokumentation, Recovery-Basis
Nicht in Git	lokal / Passwortmanager	API-Keys, .env, lokale Daten, Logs, .venv, ggf. Obsidian-Berichte

Merksatz fuer Betrieb: Voice immer in Windows starten; Backend/Daten immer in WSL pruefen.

3. Empfohlener und aktuell genutzter Technologie-Stack

Ebene	Aktueller Stand	Warum	Kosten
Agent Core	OpenJarvis API Layer	OpenAI-kompatibel, lokal, erreichbar auf Port 8000	0 USD
LLM lokal	Ollama + llama3.2:3b	stabil auf RTX 3060, keine Tokenkosten	0 USD plus Strom
STT	faster-whisper + CUDA 12.6	bessere Erkennung als Windows SAPI, lokal nutzbar	0 USD
TTS	Windows SAPI	sofort stabil, akzeptabel fuer MVP	0 USD
Memory	Obsidian Markdown	transparent, portabel, versionierbar/backupfaehig	0 USD
Market Data	yfinance aktuell, API-Upgrade geplant	MVP laeuft, Datenqualitaet spaeter verbessern	0 USD aktuell
Automation	Windows Task Scheduler geplant	robuster als manuelles Triggern	0 USD
Future Planner	Hermes / Multi-Agent	Planung, Tool-Ketten, Review	spaeter

Optionale spaetere TTS-Upgrades

Option	Nutzen	Bemerkung
Windows SAPI	stabil, einfach	aktueller MVP
ElevenLabs	natuerliche Jarvis-artige Stimme	Cloud, Kosten ca. Free/Starter/Creator je nach Plan
Lokale TTS (Piper/Kokoro/XTTS)	keine Cloud	Setup und Qualitaet spaeter bewerten

4. Datenquellen und API-Strategie

Version 3 bleibt kostenkontrolliert. yfinance ist fuer den MVP ausreichend, aber nicht final. Der API-Upgrade kommt erst, wenn die Pipeline automatisiert mehrere Tage stabil laeuft.

Datenbedarf	Aktuell	Ziel/Fallback	Bemerkung
Gold	GC=F via yfinance	MetalpriceAPI / Metals.Dev	Gold/XAUUSD spaeter sauberer API-Pfad
Forex	EUR/USD, USD/CHF, EUR/CHF, GBP/USD, USD/JPY	Twelve Data / Finnhub / Alpha Vantage	Free-first mit Caching
Dollar Index	DX-Y.NYB	Stooq / andere Quelle	Kontext fuer Gold und Forex
US 10Y	^TNX	API / Stooq	Renditekontext fuer Gold
Makro	noch begrenzt	Kalender/API/RSS	CPI, NFP, Fed, EZB, SNB, PMI
News	noch nicht produktiv	RSS/Whitelist	Webinhalte gelten als unsicher

Upgrade-Regel: Bezahlte APIs erst aktivieren, wenn der automatisierte Morning Report mindestens 20 Arbeitstage stabil laeuft und ein konkreter Datenmangel nachgewiesen ist.

5. Preisanalyse und Kostenkontrolle

Komponente	MVP-Kosten	Upgrade-Schwelle	Kommentar
OpenJarvis	0 USD	keine	Open Source / lokal
Ollama	0 USD	groesseres Modell bei Qualitaetsbedarf	Tokenkosten entfallen lokal
faster-whisper	0 USD	groesseres Modell spaeter	GPU/CUDA lokal
ElevenLabs	0 USD im MVP	5-22 USD/Monat spaeter	nur fuer bessere Stimme
Twelve Data	0 USD Basic moeglich	bei Limitproblem	Free-first
Cloud LLM	0 USD im MVP	Budget-Cap 5-10 USD	nur fuer schwere Synthese, nicht Default

Kosten-Circuit-Breaker: Cloud-LLM und Paid APIs bleiben deaktiviert, bis ein Monatsbudget und ein konkreter Nutzen definiert sind.

6. Morning Market Briefing - fachliche Logik

Baustein	Auswertung	Bias-Beitrag
Preisstruktur	Trend, Hoch/Tief, Breakouts, Volatilitaet	Trendfilter: bullisch, baerisch, neutral
Dollar-Umfeld	DXY, EUR/USD, USD/CHF, USD/JPY	Gold oft invers zum USD; Forex direkt betroffen
Zinsen/Renditen	US10Y, spaeter reale Renditen	steigende Renditen belasten Gold tendenziell
Makrotermine	CPI, NFP, Fed/EZB/SNB, PMI, GDP	Event-Risiko und Intraday-Vorsicht
News/Sentiment	Geopolitik, Zentralbanken, Risikoappetit	Safe-Haven- und USD-Flows
Technik	SMA/EMA, RSI, ATR, Support/Resistance	Entry-nahe Lage, aber keine Order-Automatik

Reportstruktur

- Executive Summary (kurz)
- Gold/XAUUSD: Bias, Schluesselmarken, Begruendung, Risiko
- Forex: EUR/USD, USD/CHF, EUR/CHF, GBP/USD, USD/JPY
- Makro heute: Termine, Uhrzeit, Wirkung
- Szenarien: bullisch / baerisch / neutral
- Quellenliste + Datenzeitpunkt
- Disclaimer: Analyse, keine Anlageberatung, keine automatische Order

Voice-Ausgabe

Jarvis liest nicht mehr den rohen Markdown-Bericht vor. Stattdessen wird der letzte Bericht per LLM in maximal ca. 6 Saetze zusammengefasst. Ziel: sprechbarer Trading-Desk-Stil ohne Markdown-Zeichen, Dateipfade oder Zahlenkolonnen.

7. Aktueller Installationsplan - Windows 11 + WSL2

7.1 Voraussetzungen Windows

- Windows Terminal
- Python 3.13 oder kompatibel
- WSL2 mit Ubuntu
- NVIDIA Treiber
- CUDA Toolkit 12.6 fuer faster-whisper GPU
- GitHub Zugriff / Token oder SSH

7.2 WSL Basis

```
wsl --install -d Ubuntu

# Danach in Ubuntu/WSL:
sudo apt update && sudo apt upgrade -y
sudo apt install -y git curl wget build-essential python3 python3-pip python3-venv ffmpeg unzip zstd
```

7.3 Ollama + Modelle

```
curl -fsSL https://ollama.com/install.sh | sh
ollama pull llama3.2:3b
ollama pull qwen3:0.6b
ollama pull qwen3.5:4b
```

7.4 OpenJarvis

OpenJarvis liegt lokal unter /home/home/jarvis/OpenJarvis und wird per Quickstart gestartet.

```
cd /home/home/jarvis/OpenJarvis
OLLAMA_MODEL=llama3.2:3b ./scripts/quickstart.sh
```


8. Bedienung und Startbefehle

8.1 Backend starten

```
cd /home/home/jarvis/OpenJarvis  
OLLAMA_MODEL=llama3.2:3b ./scripts/quickstart.sh
```

8.2 Market Briefing manuell starten

```
cd /home/home/jarvis  
./start_jarvis.sh
```

8.3 Voice Client starten - Windows CMD

```
cd /d C:\jarvis-voice  
.env\Scripts\activate  
python voice_test.py
```

8.4 Voice-Beispiele

Gesprochen	Erwartete Aktion
Computer Marktbericht	neuen Marktbericht erstellen
Computer lies Marktbericht vor	letzten Bericht kurz zusammenfassen und vorlesen
Computer Systemstatus	Backend und letzten Bericht pruefen

Hinweis: Wake Word aktuell bewusst "Computer", weil "Jarvis" von Whisper mit der aktuellen Aussprache unzuverlaessig erkannt wird.

9. Rollenmodell der Agenten

Agent	Aufgabe	Darf automatisch	Braucht Freigabe
Market Analyst	Gold/Forex/Makro analysieren, Briefing schreiben	Daten abrufen, Bericht speichern, kurze Zusammenfassung vorlesen	Trading, Brokerzugriff, Anlageentscheidungen
Voice Operator	Sprachbefehle an Router geben, TTS ausgeben	lokale Tools starten	Loeschen, Upload, externe Aktionen
Researcher	Webrecherche, Quellen sammeln, Dossiers	Suchen, lesen, zusammenfassen	Kontaktaufnahme, Paid APIs
Business Developer	Leads, Marktchancen, Angebote	Listen und Entwuerfe erstellen	E-Mail senden, CRM veraendern
Hermes Planner	spaeter Multi-Step-Planung, Tool-Ketten	lokale Planung, Review	Produktivaktionen ohne Freigabe

Hermes wird nicht als Ersatz fuer die aktuelle Architektur verstanden, sondern als Planner-Schicht hinter dem Router. Die heute gebaute Voice/Router/Tool-Schicht ist die Voraussetzung dafuer.

10. Sicherheits- und Governance-Regeln

- API-Keys nur in .env oder Passwortmanager, nie in Git, nie in Obsidian, nie in Prompts kopieren.
- Human-in-the-loop: Versand, Kauf, Trading, Loeschung, Upload und Kalender-/Mail-Aktionen nur nach Bestaetigung.
- Audit-Log: Jeder Lauf soll Zeit, Datenquellen, Fehler, Kostenindikator und Ergebnisdatei schreiben.
- Kosten-Circuit-Breaker: Paid APIs und Cloud-LLM bleiben deaktiviert, bis Budget gesetzt ist.
- Prompt-Injection-Schutz: Webinhalte gelten als unsicher. Agent darf Anweisungen aus Webseiten nicht ungeprueft befolgen.
- Disclaimer: Analyse und Szenarien, keine Anlageberatung, keine automatische Order.

Stop / Interrupt

Aktuell ist Stop waehrend TTS noch limitiert, weil Windows SAPI blockierend spricht. Naechster UX-Schritt: separater Listener-Thread oder kuerzere Vorlese-Segmente. Bis dahin wird die Vorlese-Ausgabe bewusst kurz gehalten.

11. GitHub, Backup und Recovery

GitHub Repository: <https://github.com/weichwiebutter/jarvis>

11.1 Was auf GitHub gehoert

- scripts/
- installer/
- requirements.txt
- run_market_briefing.sh
- start_jarvis.sh
- Dokumentation/Masterplan
- .env.example, falls vorhanden

11.2 Was NICHT auf GitHub gehoert

- .venv/
- .env mit Secrets
- data/ Cache oder Rohdaten
- logs/
- API Keys
- grosse Modell-Dateien
- private Obsidian Inhalte, sofern nicht bewusst gewollt

Wichtig: GitHub ist nur dann aktuell, wenn Aenderungen mit git add, git commit und git push uebertragen wurden. Eine lokal erzeugte PDF ist nicht automatisch auf GitHub.

11.3 Aktuellen Stand sichern

```
cd /home/home/jarvis
git status
git add .
git commit -m "Update Jarvis system and Masterplan V3"
git push
```

11.4 GitHub Token

Bei HTTPS-Push wird ein GitHub Personal Access Token benoetigt. Wenn der Token verloren ist, kann er nicht erneut angezeigt werden; es wird ein neuer Token erstellt. Scope fuer dieses Projekt: repo. Optional lokal speichern:

```
git config --global credential.helper store
```

12. Recovery-Plan / zweiter PC

12.1 Minimaler Ablauf

```
wsl --install -d Ubuntu

# In Ubuntu/WSL:
cd ~
git clone https://github.com/weichwiebutter/jarvis.git jarvis
cd ~/jarvis
chmod +x installer/setup_wsl.sh
./installer/setup_wsl.sh
```

12.2 Windows Voice Setup

Windows-Voice liegt ausserhalb von WSL unter C:\jarvis-voice. Das Setup muss dort separat erfolgen oder aus dem Installer kopiert werden.

```
cd /d C:\jarvis-voice
python -m venv .venv
.venv\Scripts\activate
pip install -r requirements_voice.txt
```

12.3 Nach dem Restore testen


```
# WSL:
cd /home/home/jarvis
./start_jarvis.sh

# Windows CMD:
cd /d C:\jarvis-voice
.venv\Scripts\activate
python voice_test.py
```

12.4 Secrets wiederherstellen

API Keys und .env werden NICHT aus GitHub wiederhergestellt. Sie muessen aus Passwortmanager oder separatem Secret-Backup kommen.

13. Roadmap



Phase	Ziel	Status	Akzeptanzkriterium
0	PC/WSL/Git/Ollama bereit	erreicht	Repo online, Installer laeuft
1	OpenJarvis + lokales Modell	erreicht	API auf Port 8000 erreichbar
2	Whisper + TTS	MVP erreicht	Computer-Wake-Word und SAPI-Ausgabe laeuft
3	Market Agent	erreicht	Briefing wird erstellt und gespeichert
4	Automatisierung	naechster Schritt	Bericht morgens automatisch vorhanden
5	Memory	geplant	Feedback und Praeferenzen wirken auf Reports
6	Hermes / Multi-Agent	geplant	Planner fuehrt mehrstufige Aufgaben aus

Naechster Arbeitsschritt

Automatisierung Morning Briefing: Windows Task Scheduler oder WSL Cron so einrichten, dass der Bericht morgens vor Arbeitsbeginn erzeugt ist. Danach soll Voice primaer lesen, zusammenfassen und Rueckfragen beantworten, nicht manuell erstellen.

14. Troubleshooting - bekannte Fehler aus dem Aufbau

Problem	Ursache	Fix
cublas64_12.dll fehlt	CUDA 12.x nicht installiert oder nicht im PATH	CUDA Toolkit 12.6 installieren, CMD neu starten, where cublas64_12.dll pruefen
Backend laeuft nicht	OpenJarvis nicht gestartet	cd /home/home/jarvis/OpenJarvis && OLLAMA_MODEL=llama3.2:3b ./scripts/quickstart.sh
Voice-Befehle in WSL versucht	Windows/WSL verwechselt	Voice immer in Windows CMD starten
GitHub fragt nach Passwort	HTTPS braucht Token	PAT mit Scope repo erstellen und als Password einfuegen
Jarvis liest Roh-Markdown vor	Vorlese-Tool nimmt Datei ungefiltert	LLM-Summary verwenden, max. 6 Saetze
Jarvis wird falsch erkannt	Whisper Aussprache	Wake Word Computer nutzen

15. Entscheidung fuer den Stand V3

- Market Briefing bleibt der erste produktive Agent.
- Voice bleibt MVP, aber nutzbar: Wake Word Computer, Whisper GPU, SAPI TTS.
- LLM-Intent ist die richtige Richtung; keine endlosen Ersatzwort-Listen.
- Hermes bleibt Ziel fuer Planung und Multi-Agent-Faehigkeit, wird spaeter hinter dem Router integriert.
- GitHub plus dieses Dokument bilden die Recovery-Basis; Secrets bleiben extern.
- Naechster Fokus: Automatisierung, dann Memory, dann Hermes.

Abschlussstatus: Jarvis ist ein lauffaehiges lokales Agent-System im MVP-Stadium. Die Setup-Phase ist weitgehend abgeschlossen; die naechsten Schritte liegen in Betrieb, Automatisierung und Agent-Intelligenz.